

Thinking Mode 的影響

Qwen3 candidate vs GPT-5 golden (transcript only). 指標: Cohen's kappa

模型	Thinking ON kappa	Thinking OFF kappa	變化
Qwen3-4B	0.587	0.284	-0.303
Qwen3-14B	0.616	0.178	-0.438

原因：關掉 thinking 後，模型大量輸出 UNKNOWN（放棄判斷）

	輸出 UNKNOWN 次數	佔比 (共 236 句)
Golden (GPT-5)	1	0.4%
Qwen3-4B (no think)	72	31%
Qwen3-14B (no think)	146	62%

結論：不能關 thinking。模型越大越「聽話」地遵守 prompt 中「不確定就選 UNKNOWN」的指示，反而分數更低——測到的不是真實判斷能力。

註：Thinking ON 於 30 句子集、OFF 於 236 句完整會議，兩組資料與 window 設定不同，數值不宜直接相減；但 UNKNOWN 比例的差異足以說明趨勢。

模型大小比較（Thinking ON）

AMI ES2002a 前 30 句. Qwen3 candidate vs GPT-5 golden, 皆為 transcript only

模型	exact match	kappa	macro F1
Qwen3-4B	0.667	0.587	0.695
Qwen3-8B *	0.567	0.466	0.452
Qwen3-14B	0.700	0.616	0.515

4B → 14B：主要弱點（GROUP 被誤判為 B）確實改善

	Qwen3-4B	Qwen3-14B
GROUP 誤判為 B 的次數	7	3
GROUP recall	0.429	0.643

結論：模型越大越準，方向正確，但 kappa 0.616 仍未達可信門檻 0.75。

下一步：跑 32B、擴大測試樣本。

* 8B 使用不同推論引擎與 token 上限（vLLM / 4096，其餘為 HF / 8192），不可與 4B、14B 直接比較；
4B vs 14B 為同設定的乾淨對照。