

# 1. Thinking Mode 的影響（準確度）

Qwen3 candidate vs GPT-5 golden (transcript only). 指標: Cohen's kappa

| 模型        | Thinking ON<br>kappa | Thinking OFF<br>kappa | 變化     |
|-----------|----------------------|-----------------------|--------|
| Qwen3-4B  | 0.587                | 0.284                 | -0.303 |
| Qwen3-14B | 0.616                | 0.178                 | -0.438 |

原因：關掉 thinking 後，模型大量輸出 UNKNOWN（放棄判斷）

|                      | 輸出 UNKNOWN 次數 | 佔比 (共 236 句) |
|----------------------|---------------|--------------|
| Golden (GPT-5)       | 1             | 0.4%         |
| Qwen3-4B (no think)  | 72            | 31%          |
| Qwen3-14B (no think) | 146           | 62%          |

結論：不能關 thinking。模型越大越「聽話」地遵守 prompt 中「不確定就選 UNKNOWN」的指示，反而分數更低——測到的不是真實判斷能力。

註：Thinking ON 於 30 句子集、OFF 於 236 句完整會議，兩組資料與 window 設定不同，數值不宜直接相減；但 UNKNOWN 比例的差異足以說明趨勢。

## 2. 模型大小比較（準確度，Thinking ON)

AMI ES2002a 前 30 句. Qwen3 candidate vs GPT-5 golden, 皆為 transcript only

| 模型         | exact match | kappa | macro F1 |
|------------|-------------|-------|----------|
| Qwen3-4B   | 0.667       | 0.587 | 0.695    |
| Qwen3-8B * | 0.567       | 0.466 | 0.452    |
| Qwen3-14B  | 0.700       | 0.616 | 0.515    |

### 4B → 14B：主要弱點（GROUP 被誤判為 B）確實改善

|                 | Qwen3-4B | Qwen3-14B |
|-----------------|----------|-----------|
| GROUP 誤判為 B 的次數 | 7        | 3         |
| GROUP recall    | 0.429    | 0.643     |

結論：模型越大越準，方向正確，但 kappa 0.616 仍未達可信門檻 0.75。

下一步：跑 32B、擴大測試樣本。

\* 8B 使用不同推論引擎與 token 上限（vLLM / 4096，其餘為 HF / 8192），不可與 4B、14B 直接比較；  
4B vs 14B 為同設定的乾淨對照。

### 3. 推論引擎比較： HuggingFace vs vLLM （速度）

同一份 4.1 分鐘 AMI 音檔逐字稿． H100 NVL 單卡． 所有模型設定完全相同

| 模型        | HF tok/s | vLLM tok/s | 加速倍數  | vLLM 生成時間 |
|-----------|----------|------------|-------|-----------|
| Qwen3-4B  | 17.4     | 282.9      | 16.3x | 11.3 s    |
| Qwen3-8B  | 失敗 *     | 188.3      | —     | 18.1 s    |
| Qwen3-14B | 16.5     | 114.1      | 6.9x  | 25.8 s    |
| Qwen3-32B | 12.8     | 52.2       | 4.1x  | 52.5 s    |

關鍵發現： HF 測到的是框架開銷，不是模型速度

- HF： 4B 與 14B 只差 5%（17.4 vs 16.5）——參數量差 3.5 倍卻幾乎同速，瓶頸在 Python 逐 token 開銷
- vLLM： 4B → 32B 拉開 5.4 倍差距——參數量翻倍、速度大致減半，符合記憶體頻寬受限的理論預期

結論： 大量標註務必使用 vLLM。 先前以 HF 得出的速度數據不具參考價值，已作廢。

\* 8B 在 HF 因 token 上限不足導致整個 window 解析失敗（fail=38），無有效速度數據。  
表中為純生成時間，不含一次性模型載入（vLLM 需額外編譯 CUDA graph，約 90-180 秒）。

# 4. 200 小時語料的處理時間估算

由 4.1 分鐘實測生成時間線性外推。單張 H100 NVL，循序處理

| 模型        | 處理 1 小時音檔<br>所需時間 | vLLM<br>200 小時 | HF<br>200 小時 |
|-----------|-------------------|----------------|--------------|
| Qwen3-4B  | 2.8 分             | 9.2 小時         | 154.7 小時     |
| Qwen3-8B  | 4.4 分             | 14.7 小時        | —            |
| Qwen3-14B | 6.3 分             | 21.0 小時        | 179.1 小時     |
| Qwen3-32B | 12.8 分            | 42.7 小時        | 189.3 小時     |

## 實務意涵

- 即使是最大的 32B，200 小時語料也只需 約 1.8 天 即可標註完成——模型大小不再是瓶頸
- 準確度優先於速度：42.7 小時與 9.2 小時的差距，遠小於標註品質不足需重做的代價

結論：以 32B 標註全部語料在時間上完全可行，應以準確度為選型依據。

估算僅計生成時間，不含一次性模型載入。本次為循序處理，未使用 vLLM 的連續批次（continuous batching）——實際批次處理可再快數倍，故上表為保守上限。